

UniSim-SLAM: Feed-Forward SLAM with Unified Sim(3) Optimization


Inha Lee¹, Dongjae Jeong¹, Junhee Lee¹, Kyungdon Joo^{1,†}

ECCV 2026

발표자: 송우석

Demo

x5



Intro

- 최근 연구들에 따르면, geometric foundation models이 visual SLAM 시스템의 구조를 바꾸고 있음 (e.g. DUS3R, VGGT)
 - feed-forward models을 특정 view subsets에 적용하기 시작함
 - image pairs
 - multi-view image clips
 - 각 추론된 결과를 local 좌표계에서 정의한 local reconstruction으로 하여 global coordinate system에서 정렬
- 문제점
 - geometric estimates이 input view configuration에 제약이 있고, 예측이 장기 시퀀스로 이어지면서 geometric inconsistencies를 유발

⇒ 따라서, global trajectory는 다수의 각 고유의 좌표계에서 정의된 configuration-dependent local reconstructions을 정렬함으로써 만들어져야 함

Visual SLAM

- feature-based methods
 - SfM pipeline을 따르며, keypoint matching을 이용하여 triangulation, PnP 수행
- direct methods
 - 보통 frame별 depth estimation과 함께 photometric residuals을 최소화하여 camera pose를 최적화함
→ 하지만 이들은 camera calibration과 challenging visual conditions에 민감
- learning-based SLAM
 - deep neural network를 frontend나 scene representation에 통합하여 강건성을 높이고, densify mapping을 이룸
- Neural implicit mapping
 - camera poses와 implicit scene representation을 online으로 동시 최적화
- 3DGS
 - poses와 Gaussian primitives를 동시 최적화

⇒ 그럼에도 불구하고, 대부분의 learning-based 및 neural mapping 방법론들은 정확한 intrinsics에 의존하거나 실시간 이용을 제한하는 무거운 연산량을 지님


Feed-Forward Visual SLAM

- 3D geometric foundation model을 이용해 geometry와 camera parameter를 feed-forward 방식으로 예측하게 함
 - handcrafted correspondences와 heavy per-sequence optimization에 대한 의존을 줄임
- pairwise feed-forward models
 - uncalibrated image pair 를 입력받아 3차원 구조와 dense correspondence를 예측
 - retrieval-based view graphs와 global alignment를 통해 unconstrained collections으로 확장 가능
 - + Memory or state-based models, multi-view foundation models 등으로 확장 가능
- feed-forward visual SLAM 방법론 등장
 - two-view pipeline (e.g. MAST3R-SLAM, ViSTA-SLAM)
 - pairwise prediction과 lightweight global optimization을 수행
 - multi-view pipeline (e.g. VGGT-SLAM)
 - multi-view reconstruction backbone으로 만들어진 submap들을 점진적으로 정렬 및 전역적으로 최적화하는데 집중

⇒ 하지만 대부분의 feed-forward SLAM 시스템들은 two-view temporal constraints나 multi-view submap constraints 중에 하나만 이용함

Inference

- Two-View (e.g. DUST3R)



- 연산이 가벼움

- 새로운 프레임을 받자마자 동작하여 자연스럽게 temporal connectivity를 유지하면서 low latency를 보임

→ 하지만 제한된 geometric constraints 때문에, 시간에 따른 drift 축적되기 쉬움

→ long-term global consistency를 유지하기에 불충분함

- Multi-View (e.g. VGGT)


- 풍부한 geometric constraints을 이용하지만 추론 전에 고정된 개수의 프레임들을 누적시키는 것을 필요로 함 (i.e., submap)

→ per-frame updates를 비실용적으로 만듦

- submap간의 관계만 이용한 보정(refinement)는 trajectory를 따라 correction을 전파하기 위해 이웃하는 submap들간의 겹침(overlap)이 필요함

- 특히, 겹침이 없을 때, geometric corrections은 효과적으로 전파될 수 없음

→ global consistency가 제한됨




⇒ low-latency tracking과 long-term geometric consistency간의 trade-off를 다루기 위해 고전(classic) SLAM 시스템의 구조 원리를 재방문

Classical SLAM System

- 앞 문제와 비슷한 efficiency-consistency trade-off를 완화함
 - frontend: lightweight two-view odometry
 - backend: intermittent(간헐적) globally consistent refinement
 - 이는 two-view inference의 temporal consistency를 통해 강건한 graph connectivity를 보장하고, 동시에 multi-view submap의 rich geometric constraints를 이용함
 - 하지만 기존 feed-forward 방법들은 보통 pairwise two-view alignment나 submap-to-submap registration 중에 하나만 수행함
- two-view와 multi-view predictions을 naïvely하게 합치는 것은 non-trivial한데, 이는 해당 prediction들의 scale과 reference frame이 일치하지 않는 heterogeneous local coordinate systems에 속하기 때문
 - 따라서, 새로운 factor graph formulation은 이러한 heterogeneous constraints를 single unified framework 내에서 동시에 최적화 하는 것이 필요함


⇒ UniSim-SLAM의 등장

UniSim-SLAM



- two-view와 multi-view inference를 하나의 $Sim(3)$ factor graph 내에서 통합하는 feed-forward SLAM system (둘 다 활용)
- 서로 다른 feed-forward inference 방법에서 얻은 geometric prediction을 heterogeneous local 좌표계 시스템에서 상호보완적인 constraints로 통합하기 위해 unified $Sim(3)$ factor graph에서 동시에 최적화
- feed-forward SLAM에서 효율성-일관성 trade-off를 해결하고 low-latency tracking과 long-term geometric stability를 달성하여 표준 SLAM benchmarks에서 SoTA급 성능을 보여줌

UniSim-SLAM



Two-View Tracking on Keyframes

- frontend는 low latency와 temporal consistency를 보장

$\{T_i\}$: global keyframe poses

$\{S_m\}$: submap poses

keyframe I_i 에서 I_j 로의 상대 변환 $\in Sim(3)$

(I_i, I_j) : keyframe pair (with $j = i + 1$)

$$\{\hat{D}_i^{2v}, \hat{D}_j^{2v}, \hat{T}_{ij}^{2v}\} = f_{2v}(I_i, I_j), \quad (1)$$

keyframe I_i 의 predicted depth map

two-view feed-forward model

- 첫 번째 keyframe I_0 이 전역 좌표계의 origin (global reference frame)
- 순차적으로 global pose를 추정하고, 결과로 나온 궤적이 초기 추정치가 됨

$$T_j = T_i \hat{T}_{ij}^{2v}, \quad (2) \quad \Rightarrow \text{나중에 backend에서 multi-view submap constraints로 보정}$$

Multi-view Submap Integration

- backend의 목표
 - global pose $\{T_i\}$ 에 누적된 drift를 보정하는 것
 - 이를 위해 multi-view submaps을 형성하여 주기적으로 global pose graph에 geometrically rich constraints를 끼워 넣음

- submap

$$\mathcal{W}_m \subset \{1, \dots, N\}$$

keyframe index

- corresponding keyframe sequence

$$\mathcal{I}_m = \{I_i\}_{i \in \mathcal{W}_m}$$

- feed forward multi-view model

$$\{\hat{D}_{mi}^{mv}, \hat{T}_{mi}^{mv}, \}_{i \in \mathcal{W}_m} = f_{mv}(\mathcal{I}_m), \quad (3)$$

multi-view feed-forward model

submap-local pose (submap origin keyframe을 기준으로 각 keyframe i 의 변환을 의미)

Multi-view Submap Integration

- submap origin
 - $\mathcal{W}_m$ 의 center keyframe을 submap의 origin keyframe으로 정의
- submap pose
 - submap에서 만들어지는 local reconstruction을 global trajectory에 통합하기 위해, submap pose $S_m \in Sim(3)$ 을 제안하며 이는 m번째 submap 좌표계를 global frame으로 변환함

$$T_i \approx S_m \hat{T}_{mi}^{mv}. \quad (4)$$

- problem
 - multi-view prediction이 view-set dependent하기 때문에, 동일한 keyframe은 submap에 따라 scale과 pose가 달라질 수 있음
 - 따라서 submap-local pose가 globally consistent measurement가 되기 위해서는 submap pose $\{S_m\}$ 을 명시적으로 초기화 해줘야 함

$$\hat{T}_{mi}^{mv} = \mathbf{I}$$

여기서 I_i 는 submap의 origin keyframe을 의미

Multi-view Submap Integration

- two-view inference에서 얻은 global pose

$$T_i = \begin{bmatrix} s_i R_i & t_i \\ 0^T & 1 \end{bmatrix}, \quad \begin{array}{l} \bullet R_i \in \text{SO}(3) \\ \bullet t_i \in \mathbb{R}^3 \\ \bullet s_i \in \mathbb{R}^+ \end{array}$$

- two-view와 multi-view prediction간의 relative scale ambiguity를 해결하기 위해, depth statistics을 사용한 relative scale을 추정

- $s_{mi}^{\text{rel}} = \text{median}(\hat{D}_{mi}^{\text{mv}} / \hat{D}_i^{2\text{v}})$

→ depth statistics

- $s_m^{(0)} = s_i / s_{mi}^{\text{rel}}$

→ 초기 submap scale (multi-view prediction은 unit scale로 표현되기 때문)

Multi-view Submap Integration

- submap pose

$$S_m^{(0)} = \begin{bmatrix} s_m^{(0)} R_i & \frac{t_i}{s_{mi}^{\text{rel}}} \\ 0^\top & 1 \end{bmatrix}.$$

global frame과 submap frame간의 similarity transformation
을 보존하기 위해 동일한 relative factor로 scaling

(6)

- submap의 scale-consistent embedding을 global trajectory에 제공하고, 그 후에 T_i 와 S_m 둘 다 unified optimization으로 동시에 최적화됨
- 하지만 two-view와 multi-view constraints가 동시에 적용될 때, 다수의 Sim(3) 관계가 하나의 submap에서 공존하게 됨
 - 각 keyframe은 global pose T_i 와 associate되고, submap은 Sim(3) 변수 S_m 과 associate

⇒ 따라서, 초기화 단계에서 하나의 relative scale constraint를 강제하는 것은 global consistency를 보장하기에 불충분함


⇒ multi-level factor graph formulation 등장

Unified Sim(3) Pose Graph

- two-view, multi-view feed-forward inferences는 서로 다른 좌표계에서 독립적인 scale로 Sim(3) predictions을 생성
- 전통적인 pose graph로 이러한 heterogenous constraints를 직접적으로 강제하는 것은 호환되지 않는 similarity relations와 불안정한 최적화를 초래할 수 있음

→ 이러한 구조적 비일관성을 극복하기 위해, Sim(3) manifold에서 직접적으로 unified multi-level pose graph를 고안했으며, 이는 pairwise나 submap constraints로만 최적화하는 이전 파이프라인들과 달리, 모든 heterogeneous Sim(3) relations를 하나의 similarity-consistent graph에 모델링함

- Unified Graph

$$\mathcal{G} = (\mathcal{V}, \mathcal{E})$$


$$\mathcal{V} = \mathcal{V}_T \cup \mathcal{V}_S, \quad \mathcal{V}_T = \{T_i \in Sim(3)\}, \quad \mathcal{V}_S = \{S_m \in Sim(3)\}$$

$$\mathcal{E} = \mathcal{E}^{\text{temp}} \cup \mathcal{E}^{v2s} \cup \mathcal{E}^{s2s}$$

edge set은 3개의 계층 구조로 나뉨

Unified Sim(3) Pose Graph

- edge set

$$\mathcal{E} = \mathcal{E}^{\text{temp}} \cup \mathcal{E}^{v2s} \cup \mathcal{E}^{s2s}$$

$\mathcal{E}^{\text{temp}}$: temporal edges (View-to-View Edges)

→ 연결성을 보장하기 위해 연속적인 global poses를 연결

$\mathcal{E}^{v2s}$: View-to-Submap edges

→ T_i 를 S_m 과 연결하여 local predictions을 정렬하고, relative scales을 제한

$\mathcal{E}^{s2s}$: Submap-to-Submap edges

→ 직접적으로 overlapping submaps을 연결하여 similarity consistency를 강제하고 scale drift를 예방

⇒ 각각의 edge set에 걸쳐 geometric relationship을 인코딩

Unified Sim(3) Pose Graph

- View-to-View Edges

$$\mathcal{E}^{\text{temp}} = \{(i, j) | j = i + 1\}$$

- 각 $(i, j) \in \mathcal{E}^{\text{temp}}$ 에 대해 two-view feed-forward model은 relative Sim(3) measurement $\hat{T}_{ij}^{2v}$ 를 제공
- global pose와 pairwise feed-forward prediction간의 agreement를 enforce하는 temporal consistency constraints
적용

$$T_i^{-1}T_j \approx \hat{T}_{ij}^{2v}$$

- two-view residual

$$\mathbf{e}_{ij}^{2v} = \log \left((\hat{T}_{ij}^{2v})^{-1} (T_i^{-1}T_j) \right)$$


Unified Sim(3) Pose Graph

- View-to-Submap Edges

$$\mathcal{E}^{v2s} = \{(m, i) | i \in W_m\}$$


- global pose node T_i 와 대응하는 submap pose node S_m 을 연결
- 각 $(m, i) \in \mathcal{E}^{v2s}$ 에 대해, submap m 은 submap-local pose $\hat{T}_{mi}^{mv}$ 를 가짐

- 2개의 residual terms

- pose alignment (bridge residual)

$$T_i \approx S_m \hat{T}_{mi}^{mv}$$

$$\mathbf{e}_{mi}^{br} = \log \left((\hat{T}_{mi}^{mv})^{-1} S_m^{-1} T_i \right)$$



⇒ 하지만, pose alignment만으로는 global trajectory와 submap 좌표계간의 relative scale에 제약을 주지 못함

- scale anchoring (anchor residual)

$$\mathbf{e}_{mi}^{anch} = \log s_i - \log s_m - \log \left(\text{median}(\hat{D}_{mi}^{mv} / \hat{D}_i^{2v}) \right)$$


$\hat{D}_i^{2v}$: predicted two-view depth
 $\hat{D}_{mi}^{mv}$: predicted multi-view depth

Unified Sim(3) Pose Graph

- View-to-Submap Edges 만으로는 global view nodes를 통해 submap들간의 간접적인 정렬을 가능하게 하지만, 해당 coupling은 중간 view node들을 교체하는 식으로 보완될 수도 있음
- bridge residual

$$\mathbf{e}_{mi}^{\text{br}} = \log \left((\hat{T}_{mi}^{\text{mv}})^{-1} S_m^{-1} T_i \right)$$

- GT가 아님 (Two-View의 초기 추정치)
→ 따라서 S_m 이 아니라 T_i 를



따라서 Submap들간에 더 엄격한 제약이 필요함

⇒ Submap-to-Submap Edges 등장

Unified Sim(3) Pose Graph

- Submap-to-Submap Edges

$$\mathcal{E}^{s2s} = \{(m, n) | \mathcal{W}_m \cap \mathcal{W}_n \neq \emptyset\}$$

$$\mathcal{V}_{mn} = \mathcal{W}_m \cap \mathcal{W}_n$$

→ 서로 keyframe window가 겹치는 submap들만 연결

→ submap m과 n간에 공유되는 keyframe들

- 2개의 residual terms

- pose consistency constraint (tie residual)

- geometric consistency를 만족하려면 multi-view inference로 submap m 과 n 각각에 대해 독립적으로 출력한 local pose predictions $\hat{T}_{mi}^{mv}$ 와 $\hat{T}_{ni}^{mv}$ 에 대해 submap 좌표계에서 공유되는 view가 동일한 global pose를 내놓아야 함

$$S_m \hat{T}_{mi}^{mv} \approx S_n \hat{T}_{ni}^{mv}$$

$$\mathbf{e}_{mni}^{\text{tie}} = \log \left((S_m \hat{T}_{mi}^{mv})^{-1} (S_n \hat{T}_{ni}^{mv}) \right)$$

- scale consistency constraint (scale residual)

$$\hat{s}_{mn,i} = \text{median}(\hat{D}_{mi}^{mv} / \hat{D}_{ni}^{mv}) \quad \hat{s}_{mn} = \text{median}_{i \in \mathcal{V}_{mn}} \hat{s}_{mn,i}$$

$$\mathbf{e}_{mn}^{\text{sc}} = \log s_n - \log s_m - \log \hat{s}_{mn}$$

⇒ 이러한 direct constraint는 중간 view들의 pose를 조정하여 submap 정렬을 이루는 degenerate solutions를 예방

Optimization

- View-to-View Edges
 - **two-view residual**: 인접 keyframe간에 실제 변환과 two-view feed-forward model로 추정된 변환이 동일해야 한다는 temporal consistency constraint를 줌
- View-to-Submap Edges
 - **bridge residual**: submap origin을 기준으로 정렬(submap-local pose)되어 있는 keyframe을 global pose로 가져오는 변환 (S_m)을 constraint로 줌
 - **anchor residual**: relative scale constraint를 주기 위해 per-view depth statistics을 이용
- Submap-to-Submap Edges
 - **tie residual**: 두 submap이 공유하는 overlapping frame에 대해 예측한 local pose prediction을 global pose로 가져왔을 때 동일한 global pose를 가져야 한다는 constraint를 줌
 - **scale residual**: overlapping frame의 scale이 동일하다는 것을 이용한 scale consistency constraint를 줌

- **Optimization Function**

$$\arg \min_{\{T_i\}, \{S_m\}} \sum_{(i,j) \in \mathcal{E}^{\text{temp}}} \rho(\|\mathbf{e}_{ij}^{2v}\|) + \sum_{(m,i) \in \mathcal{E}^{\text{v2s}}} (\rho(\|\mathbf{e}_{mi}^{\text{br}}\|) + \rho(\|\mathbf{e}_{mi}^{\text{anch}}\|)) + \sum_{(m,n) \in \mathcal{E}^{\text{s2s}}} \left(\sum_{i \in \mathcal{V}_{mn}} \rho(\|\mathbf{e}_{mni}^{\text{tie}}\|) + \rho(\|\mathbf{e}_{mn}^{\text{sc}}\|) \right),$$

huber loss function

- Loop Closure는 VGGT-SLAM 거를 갖다 씀

Experiment

- Camera Pose Estimation

Method	office0	office1	office2	office3	office4	room0	room1	room2	Avg.
MASt3R-SLAM* [26]	0.056	0.056	0.079	0.056	0.059	0.102	0.108	0.063	0.072
VGGT-SLAM [22]	0.056	0.034	0.043	0.057	0.038	0.034	0.037	0.036	0.042
ViSTA-SLAM [47]	0.074	0.193	0.118	0.048	0.130	0.069	0.093	0.136	0.108
Ours	0.068	0.018	0.022	0.020	0.028	0.023	0.021	0.028	0.029

planar structure가 대부분

Replica

Method	360	desk	desk2	floor	plant	room	rpy	teddy	xyz	Avg
Calib.	ORB-SLAM3 [3]	×	0.017	0.210	×	0.034	×	×	×	N/A
	DeepV2D [35]	0.243	0.166	0.379	1.653	0.203	0.246	0.105	0.316	0.375
	DeepFactors [4]	0.159	0.170	0.253	0.169	0.305	0.364	0.043	0.601	0.233
	DPV-SLAM [19]	0.112	0.018	0.029	0.057	0.021	0.330	0.030	0.084	0.076
	DPV-SLAM++ [19]	0.132	0.018	0.029	0.050	0.022	0.096	0.032	0.098	0.054
	GO-SLAM [49]	0.089	0.016	0.028	0.025	0.026	0.052	0.019	0.048	0.035
	DROID-SLAM [36]	0.111	0.018	0.042	0.021	0.016	0.049	0.026	0.048	0.038
	MASt3R-SLAM [26]	0.049	0.016	0.024	0.025	0.020	0.061	0.027	0.041	0.030
UnCalib.	CUT3R [40]	0.174	0.592	0.546	0.662	0.467	0.911	0.051	0.845	0.129
	SLAM3R [21]	0.211	0.861	0.967	0.790	0.755	1.013	0.063	0.986	0.185
	MASt3R-SLAM* [26]	0.070	0.032	0.055	0.056	0.035	0.118	0.041	0.116	0.020
	VGGT-SLAM [22]	0.063	0.031	0.048	0.152	0.023	0.133	0.038	0.039	0.020
	ViSTA-SLAM [47]	0.104	0.030	0.030	0.070	0.052	0.067	0.023	0.080	0.015
	UniSim-SLAM	0.067	0.018	0.022	0.034	0.029	0.056	0.021	0.031	0.013
										0.032


TUM RGB-D

Method	chess	fire	heads	office	pumpkin	kitchen	stairs	Avg.
Calib.	DROID-SLAM [36]	0.018	0.027	0.021	0.041	0.025	0.016	0.017
	MASt3R-SLAM [26]	0.082	0.030	0.024	0.052	0.050	0.044	0.027
UnCalib.	CUT3R [40]	0.514	0.110	0.197	0.430	0.346	0.202	0.385
	SLAM3R [21]	0.131	0.044	0.040	0.058	0.100	0.064	0.116
	MASt3R-SLAM [26]	0.090	0.058	0.039	0.072	0.084	0.062	0.071
	VGGT-SLAM [22]	0.039	0.024	0.041	0.032	0.050	0.034	0.042
	ViSTA-SLAM [47]	0.075	0.035	0.030	0.064	0.065	0.041	0.036
	UniSim-SLAM	0.017	0.018	0.026	0.024	0.022	0.016	0.019

7-Scenes

Experiment

- Camera Pose Estimation



7-Scenes

Experiment

- 3D Reconstruction


Method		Acc. ↓	Comp. ↓	Chamfer ↓
<i>Calib.</i>	DROID-SLAM [36]	0.111	0.049	0.080
	MASt3R-SLAM [26]	0.064	0.068	0.066
<i>Uncalib.</i>	Spann3R @5 [38]	0.095	0.041	0.068
	CUT3R [40]	0.107	0.059	0.083
	SLAM3R [21]	0.069	0.153	0.111
	MASt3R-SLAM [26]	0.054	0.048	0.051
	VGGT-SLAM [22]	0.039	0.051	0.045
	ViSTA-SLAM [47]	0.041	0.056	0.049
	UniSim-SLAM	0.035	0.046	0.041

7-Scenes

- UniSim-SLAM은 submap간에 overlapping frame을 활용하기 때문에, naïve하게 모든 reconstructed point를 합치는 것은 point density를 증가시켜 인위적인 completion metric 성능 향상을 시킬 수 있음
- 해당 bias를 없애기 위해 하위 25%의 confidence score를 가지는 point들을 제거

Experiment

- 3D Reconstruction



7-Scenes

Experiment

- Latency

(c) Latency comparison on 7-Scenes.

Method	Frontend	Latency [ms]↓	ATE↓
MASt3R-SLAM [26]	MASt3R [17]	90	0.068
VGGT-SLAM [22]	VGGT [39]	3410	0.037
ViSTA-SLAM [47]	STA [47]	35	0.049
Ours + STA [47]	STA [47]	35	0.027
Ours	VGGT [39]	197	0.020

- 여기서 latency는 최소한으로 요구되는 입력 프레임을 받았을 때부터 frontend에서 camera pose estimate를 수행하는데까지 걸린 시간을 의미
(근데 two-view를 처리하는거여서 짧은게 당연함...)
- heterogeneous feed-forward models의 prediction을 통합하면서, multi-level factor graph가 효과적으로 Sim(3) 보정을 수행할 수 있다는 것을 보여줌

- SLAM 시스템에서 입력 frame이 들어올 때, camera pose 추정은 low latency를 가정함. 따라서 tracking동안에 method별 latency를 분석함
- VGGT를 frontend로 사용했을 때 동일한 multi-view method인 VGGT-SLAM 대비 197ms라는 훨씬 적은 latency로 더 좋은 성능을 보임 (하지만 two-view method인 MASt3R-SLAM 대비 latency가 더 높았음)
- 추가적으로 frontend를 더 가벼운 STA로 교체하여 사용하니 latency가 가장 낮았던 ViSTA-SLAM만큼 가벼워졌고, VGGT frontend를 사용했던 Ours보다 성능은 낮아졌지만, 그래도 기존 baseline method들보다 훨씬 좋은 성능을 보임

Ablation Study

- Impact of Submap Configuration

w	$\phi = 1$	$\phi = 2$	$\phi = 4$	$\phi = 8$
4	0.043	0.041	—	—
8	0.035	0.035	0.035	—
16	0.031	0.032	0.031	0.030
32	0.033	0.032	0.034	0.033

- ϕ : number of overlap frame between submaps
- w : submap size

- 하나의 frame만을 공유할 때는($\phi = 1$), submap 정렬이 하나의 multi-view local pose estimation에만 의존하여, 불안정한 최적화를 유발함. (따라서 $\phi = 2$ 을 기본값으로 사용)
 - 더 큰 submap은 local multi-view estimation을 향상시키지만, graph에서 submap node의 개수는 줄게되는데, 이는 global constraints를 약화시킴. (따라서 $w = 16$ 을 기본값으로 사용)
- Effectiveness of Graph Constraints

	w/o Backend	w/o LC	w/o $\mathbf{e}^{2v}$	w/o $\mathbf{e}^{anch}$	w/o $\mathbf{e}^{br}$	w/o $\mathbf{e}^{tie}$	w/o $\mathbf{e}^{sc}$	Ours (full)
$\phi = 0$	0.124	0.061	0.101	0.083	0.116	0.040	0.048	0.032
$\phi = 2$	0.124	0.037	0.021	0.020	0.063	0.027	0.031	0.020

More Details

- residual weights

$$(w^{2v}, w^{br}, w^{anch}, w^{sc}, w^{tie}) = (1.0, 1.0, 50.0, 50.0, 0.2)$$

Residual	weights	chess	fire	heads	office	pumpkin	kitchen	stairs	Avg.
e^{sc}, e^{anch}	$w^{sc}, w^{anch} = 1$	0.030	0.024	0.027	0.027	0.021	0.022	0.028	0.025
	$w^{sc}, w^{anch} = 2$	0.024	0.022	0.027	0.026	0.021	0.021	0.025	0.024
	$w^{sc}, w^{anch} = 10$	0.018	0.019	0.027	0.025	0.021	0.019	0.020	0.021
	$w^{sc}, w^{anch} = 50$	0.017	0.018	0.026	0.024	0.022	0.016	0.019	0.020
e^{tie}	$w^{tie} = 0.2$	0.017	0.018	0.026	0.024	0.022	0.016	0.019	0.020
	$w^{tie} = 0.5$	0.018	0.018	0.026	0.024	0.021	0.015	0.019	0.020
	$w^{tie} = 1.0$	0.020	0.020	0.026	0.023	0.020	0.015	0.019	0.020
	$w^{tie} = 2.0$	0.025	0.023	0.027	0.024	0.020	0.015	0.019	0.022

scale 관련 weight가 작아질수록, tie weight이 증가할수록 성능이 감소함

7-Scenes

More Details

- residual weights

	Method	chess	fire	heads	office	pumpkin	kitchen	stairs	Avg.
overlap ($\phi = 2$)	Tracking only	0.158	0.090	0.101	0.145	0.166	0.114	0.096	0.124
	w/o Loop closure	0.020	0.024	0.029	0.075	0.036	0.050	0.023	0.037
	w/o $\mathbf{e}^{\text{sc}}$	0.045	0.032	0.027	0.030	0.023	0.022	0.036	0.031
	w/o $\mathbf{e}^{2v}$	0.020	0.018	0.026	0.024	0.023	0.016	0.019	0.021
	w/o $\mathbf{e}^{\text{anch}}$	0.019	0.018	0.026	0.024	0.022	0.015	0.018	0.020
	w/o $\mathbf{e}^{\text{br}}$	0.046	0.048	0.035	0.110	0.121	0.051	0.027	0.063
	w/o $\mathbf{e}^{\text{tie}}$	0.018	0.020	0.026	0.035	0.033	0.034	0.021	0.027
	w/o $\mathcal{E}^{v2s}$	0.158	0.090	0.101	0.145	0.166	0.114	0.096	0.124
	w/o $\mathcal{E}^{s2s}$	0.017	0.023	0.027	0.037	0.030	0.052	0.025	0.030
	Ours (full)	0.017	0.018	0.026	0.024	0.022	0.016	0.019	0.020
Non-overlap	Tracking only	0.158	0.090	0.101	0.145	0.166	0.114	0.096	0.124
	w/o Loop closure	0.106	0.045	0.035	0.074	0.075	0.059	0.033	0.061
	w/o $\mathbf{e}^{\text{sc}}$	0.117	0.056	0.032	0.033	0.037	0.033	0.030	0.048
	w/o $\mathbf{e}^{2v}$	0.157	0.064	0.059	0.065	0.162	0.111	0.085	0.101
	w/o $\mathbf{e}^{\text{anch}}$	0.178	0.185	0.070	0.047	0.020	0.042	0.040	0.083
	w/o $\mathbf{e}^{\text{br}}$	0.216	0.098	0.075	0.138	0.125	0.112	0.045	0.116
	w/o $\mathbf{e}^{\text{tie}}$	0.106	0.043	0.041	0.024	0.020	0.033	0.015	0.040
	w/o $\mathcal{E}^{v2s}$	0.158	0.090	0.101	0.145	0.166	0.114	0.096	0.124
	w/o $\mathcal{E}^{s2s}$	0.092	0.029	0.033	0.027	0.034	0.045	0.025	0.041
	Ours (full)	0.066	0.029	0.043	0.027	0.023	0.019	0.015	0.032

7-Scenes

View-to-Submap, Submap-to-Submap edge set에 대한 ablation 평가도 진행

More Details

- run time

	Frontend	Backend				
Component	Two-view inference	Submap node initialization	Descriptor extraction	Graph construction	Optimization	Multi-view inference
Latency[ms]	197	167	16	36	645	933

- frontend는 7-Scenes에서 대략 25 FPS를 달성하면서 two-view estimation을 진행
- backend는 새 프레임이 충분히 누적되었을 때만 동작
 - default configuration에서는 14개의 새로운 keyframe이 쌓였을 때 backend 과정 진행
- frontend와 backend는 분리된 thread에서 동작하기 때문에, low-latency tracking 성능을 유지하면서 backend refinement가 비동기적으로 처리됨

More Details

- run time (vs VGGT-SLAM 2.0)

	Frontend	Backend				
Component	Two-view inference	Submap node initialization	Descriptor extraction	Graph construction	Optimization	Multi-view inference
Latency[ms]	197	167	16	36	645	933

Sum: 1994

Stage	total time per submap (ms)
VGGT Inference	1248 ms
Keyframe Detection	176 ms
Loop Closure Detection	128 ms
Backend Optimization	8 ms
Semantics (optional)	368 ms

⇒ 하지만 backend는 새로운 keyframe 이 어느정도 모였을 때만 일어나기 때문에, 이를 고려했을 때 low-latency라고 볼 수 있음

VGGT-SLAM 2.0

Sum: 1928

More Details

- Other Backbone

Method		chess	fire	heads	office	pumpkin	kitchen	stairs	Avg.
Calib.	DROID-SLAM [36]	0.018	0.027	0.021	0.041	0.025	0.016	0.017	0.024
	MASt3R-SLAM [26]	0.082	0.030	0.024	0.052	0.050	0.044	0.027	0.044
Uncalib.	CUT3R [40]	0.514	0.110	0.197	0.430	0.346	0.202	0.385	0.312
	SLAM3R [21]	0.131	0.044	0.040	0.058	0.100	0.064	0.116	0.079
	MASt3R-SLAM* [26]	0.090	0.058	0.039	0.072	0.084	0.062	0.071	0.068
	VGGT-SLAM [22]	0.039	0.024	0.041	0.032	0.050	0.034	0.042	0.037
	ViSTA-SLAM [47]	0.075	0.035	0.030	0.064	0.065	0.041	0.036	0.049
	Ours + STA	0.030	0.031	0.031	0.023	0.029	0.024	0.018	0.027
	Ours	0.017	0.018	0.026	0.024	0.022	0.016	0.019	0.020


7-Scenes

Method		360	desk	desk2	floor	plant	room	rpy	teddy	xyz	Avg
Calib.	ORB-SLAM3 [3]	×	0.017	0.210	×	0.034	×	×	×	0.009	N/A
	DeepV2D [35]	0.243	0.166	0.379	1.653	0.203	0.246	0.105	0.316	0.064	0.375
	DeepFactors [4]	0.159	0.170	0.253	0.169	0.305	0.364	0.043	0.601	0.035	0.233
	DPV-SLAM [19]	0.112	0.018	0.029	0.057	0.021	0.330	0.030	0.084	0.010	0.076
	DPV-SLAM++ [19]	0.132	0.018	0.029	0.050	0.022	0.096	0.032	0.098	0.010	0.054
	GO-SLAM [49]	0.089	0.016	0.028	0.025	0.026	0.052	0.019	0.048	0.010	0.035
	DROID-SLAM [36]	0.111	0.018	0.042	0.021	0.016	0.049	0.026	0.048	0.012	0.038
	MASt3R-SLAM [26]	0.049	0.016	0.024	0.025	0.020	0.061	0.027	0.041	0.009	0.030
Uncalib.	CUT3R [40]	0.174	0.592	0.546	0.662	0.467	0.911	0.051	0.845	0.129	0.486
	SLAM3R [21]	0.211	0.861	0.967	0.790	0.755	1.013	0.063	0.986	0.185	0.648
	MASt3R-SLAM* [26]	0.070	0.032	0.055	0.056	0.035	0.118	0.041	0.116	0.020	0.060
	VGGT-SLAM [22]	0.063	0.031	0.048	0.152	0.023	0.133	0.038	0.039	0.020	0.061
	ViSTA-SLAM [47]	0.104	0.030	0.030	0.070	0.052	0.067	0.023	0.080	0.015	0.052
	Ours + STA	0.065	0.016	0.022	0.035	0.045	0.041	0.022	0.034	0.012	0.032
	Ours	0.067	0.018	0.022	0.034	0.029	0.056	0.021	0.031	0.013	0.032


TUM RGB-D

More Details

- Qualitative Result



Result with PGO



Result without PGO

7-Scenes (stairs)

- PGO를 쓰니 misalignment가 해결됨

7-Scenes chess



7-Scenes fire



7-Scenes pumpkin



TUM RGB-D desk




TUM RGB-D xyz



TUM RGB-D floor



Replica office3



Replica room0



Replica room1



Conclusion

- UniSim-SLAM은 two-view, multi-view constraint를 multi-level factor graph를 이용해 하나로 묶은 feed-forward SLAM system
- 이를 통해 low-latency로 consistent global pose estimation이 가능하게 됨
- SoTA 모델들 대비 높은 성능(camera pose estimation, 3d reconstruction)을 보임

내 생각 (왜 잘된 것 같은가?)

- 기존 multi-view method(e.g. VGGT-SLAM)가 two-view method(e.g. MAST3R-SLAM) 보다 높은 성능을 보였었는데, two-view가 기존 multi-view의 어떤 점을 보완했는가?
 - 기존 multi-view method 대비 다른점은 frontend를 two-view로 쓰고, backend에서 View-to-Submap을 통해 two-view, multi-view constraint를 하나로 묶는다는 점
 - 7-Scenes에서 진행한 ablation study에서 two-view residual은 chess sequence에서밖에 성능 향상을 보이지 않음
 - 따라서 해당 two-view residual은 scale inconsistency에 강건함을 제공하는 하지만, 성능 기여에 있어서 더 큰 비중은 View-to-Submap residual에 있는듯함
- ablation study에서 loop closure가 없어도 기존 SoTA 모델들에 comparable한 성능을 보였다고 했는데, 해당 ablation study는 어떤 데이터셋으로 진행됐었고, long-sequence에서도 비슷한 점을 보였는가?
 - 7-Scenes에서 진행되었고, 해당 데이터셋의 시퀀스 대부분은 방 1개에서 촬영
 - 따라서 long-sequence에 대한 평가는 없었고 loop closure의 필요성이 극대화되는 구역에서의 추가 평가가 필요해 보임
- TUM RGB-D floor 시퀀스가 planar structure dominant하여 scale recovery를 위한 geometric cue가 부족해, 기존 feed-forward model들은 scale drift를 발생시킨다고 했는데, UniSim-SLAM은 이러한 상황에서 어떻게 강건하게 동작할 수 있었는가?
 - 해당 시퀀스에서 성능이 VGGT-SLAM 2.0 대비 2배나 좋았음 (MASt3R-SLAM도 잘나온걸 보니 two-view inference가 이런 부분에 강건함을 주는?)
- 따로 outdoor dataset에 대한 평가가 있었는가?
 - 없었음
- 따로 추가 학습을 하는건가?
 - feed-forward model에 대한 extra training은 없음
 - 새로운 multi-level factor graph에 대한 real-time optimization만 수행되는 듯 함